



Polsko-Japońska Akademia Technik Komputerowych

Wydział Informatyki

# Zastosowanie filtrów Kalmana do poprawy predykcji cen giełdowych przy użyciu sieci LSTM

Praca Dyplomowa

**Autor:** Mikołaj Warda (s28034)

**Kierunek studiów:** Informatyka

**Specjalizacja:** Data Science

**Promotor:** dr inż. Sinh Hoa Nguyen

October 14, 2025

# **Contents**

<b>1</b>	<b>Streszczenie</b>	<b>2</b>
<b>2</b>	<b>Wstęp</b>	<b>3</b>
2.1	Tło problemu . . . . .	3
2.2	Problem badawczy . . . . .	3
2.3	Proponowane rozwiązanie . . . . .	3
2.4	Cel i zakres pracy . . . . .	3
2.5	Struktura pracy . . . . .	4
<b>3</b>	<b>Podstawy teoretyczne i przegląd literatury</b>	<b>4</b>
<b>4</b>	<b>Metodyka badań</b>	<b>4</b>
<b>5</b>	<b>Wyniki i dyskusja</b>	<b>4</b>
<b>6</b>	<b>Podsumowanie i wnioski</b>	<b>4</b>
<b>7</b>	<b>Bibliografia</b>	<b>4</b>
<b>8</b>	<b>Spis rysunków i tabel</b>	<b>4</b>
<b>9</b>	<b>Załączniki</b>	<b>4</b>

## **1. Streszczenie**

## **2. Wstęp**

### **2.1. Tło problemu**

Prognozowanie cen akcji odgrywa kluczową rolę w finansach, wspierając inwestorów w podejmowaniu świadomych decyzji zarządzania swoim portfolio. Chaotyczny charakter rynków sprawia jednak, że trafne przewidywanie notowań pozostaje trudnym zadaniem. Tradycyjna analiza techniczna bywa niewystarczająca - jest wrażliwa na szum, a wnioski często zawierają element subiektywności.

W ostatnich latach dynamiczny rozwój uczenia maszynowego, zwłaszcza sieci neuronowych, znacząco zmienił podejście do modelowania danych czasowych (w tym giełdowych). Architektury takie jak LSTM (Long Short-Term Memory) potrafią uchwycić złożone zależności i długookresowe relacje w danych, co czyni je obiecującymi narzędziami do prognozowania cen. Nawet one pozostają jednak podatne na anomalia i zakłócenia w danych, co może zniekształcać wyniki.

### **2.2. Problem badawczy**

Mimo że modele LSTM (Long Short-Term Memory) wykazują dużą skuteczność w analizie szeregów czasowych, ich praktyczne zastosowanie w prognozowaniu cen giełdowych napotyka na istotne wyzwania. Głównym problemem jest wysoka wrażliwość tych sieci na szum oraz losowe wahania, które są nieodłącznym elementem danych finansowych.

Te zniekształcenia wynikają głównie z nieprzewidywalnych zdarzeń rynkowych i mogą prowadzić do niestabilności w procesie uczenia, a zatem generowania prognoz o niskiej trafności. Model, zamiast uczyć się rzeczywistych trendów, może zacząć modelować przypadkowe zakłócenia, co obniża jego zdolność do generalizacji na nowych, niewidzianych wcześniej danych. W rezultacie, predykcje mogą być obarczone znacznym błędem, co podważa ich użyteczność w podejmowaniu decyzji inwestycyjnych.

### **2.3. Proponowane rozwiązanie**

Aby zapobiec negatywnemu wpływowi szumu na modele LSTM jest zastosowanie technik redukcji szumu w danych wejściowych. Jednym z klasycznych narzędzi tego typu jest filtr Kalmana – metoda estymacji stanu w systemach dynamicznych skażonych szumem – który może pełnić rolę modułu wygładzania i korekty obserwacji, podnosząc stabilność i dokładność predykcji. Taki filtr może działać jako warstwa przed przetwarzaniem przez LSTM, oczyszczając dane wejściowe z fluktuacji. Podanie na wejście modelu LSTM danych przefiltrowanych przez filtr Kalmana może zredukować wpływ szumu, pozwalając sieci skupić się na istotnych wzorcach i trendach.

### **2.4. Cel i zakres pracy**

Celem pracy jest zbadanie skuteczności integracji filtrów Kalmana z modelami LSTM w kontekście prognozowania cen akcji. Zakres obejmuje:

- Stworzenie bazowego modelu LSTM do prognozowania cen akcji.
- Stworzenie modelu LSTM na bazie danych wzbogaconych o dodatkowe parametry techniczne

- Implementację filtra Kalmana do przetwarzania danych wejściowych.
- Stworzenie modelu LSTM bazującego na danych przefiltrowanych przez filtr Kalmana.
- Porównanie wydajności trzech podejść na rzeczywistych danych giełdowych.

## **2.5. Struktura pracy**

W dalszej części pracy przedstawiono przegląd literatury dotyczącej prognozowania cen akcji i metod redukcji szumu. Następnie opisano zastosowaną metodykę badawczą, w tym szczegółowo implementacji modeli i filtru Kalmana oraz informacje na temat wykorzystanych technologii. Kolejna sekcja prezentuje wyniki eksperymentów oraz ich analizę. Pracę kończy podsumowanie z wnioskami i propozycjami dalszych badań.

## **3. Podstawy teoretyczne i przegląd literatury**

## **4. Metodyka badań**

## **5. Wyniki i dyskusja**

## **6. Podsumowanie i wnioski**

## **7. Bibliografia**

## **8. Spis rysunków i tabel**

## **9. Załączniki**